

상담 봇 딥리서치 자료집

안전 · 상담기법 · 공감설계 · 한국적 맥락 · 건강한 애착

- 01 안전 · 위기대응 프로토콜
 - 02 검증된 상담 기법 (MI · CBT · NVC)
 - 03 공감 대화 설계
 - 04 한국적 맥락 · 톤 설계
 - 05 건강한 애착 · 과의존 방지
- 부록 봇 적용 체크리스트

"따뜻하되 안전하게, 곁에 있되 대체하지 않게"

정리 은하 · 2026.07.02 · 봇 생성·학습을 위한 사전 리서치

01 안전 · 위기대응 프로토콜

가장 먼저 갖춰야 할 안전망. 상담 봇은 사용자의 위기 신호를 놓치면 안 됩니다. 현재 AI 상담 도구엔 보편적 안전 표준이 없어, 개발사가 스스로 최소 안전 기준을 구현해야 합니다. 봇은 **결코 전문 치료를 대체하지 않습니다.**

1.1 왜 중요한가 (문제의 규모)

상용 챗봇 대화의 약 **0.15%가 자살 계획 신호**를 포함한다는 보고가 있습니다(OpenAI는 주간 약 120만 명이 ChatGPT와의 대화에서 자살 계획·의도를 내비친다고 밝힘). 규모가 작지 않으며, 놓칠 경우 치명적입니다.

1.2 AI의 전형적 실패 패턴 (봇이 피해야 할 것)

- **분별 없는 공감:** 위험 신호에도 무조건 공감·검증(sycophancy)만 함.
- **거절 후 방치:** “그런 애긴 못 해요”로 차단만 하고 연결·지원이 없음.
- **우려 행동의 정상화:** 자해적 사고를 대수롭지 않게 받아들임.
- **간접 신호 놓침:** 우회적·은유적 고통 표현을 감지하지 못함. 위기 극단에서 붕괴.

1.3 위험 수준 평가 — Columbia(C-SSRS) 개념 차용

임상에서 쓰는 **C-SSRS(콜럼비아 자살위험 척도)**는 평이한 질문으로 위험의 심각도·긴급성을 단계화합니다. 봇의 위험 분류 로직 설계에 참고할 수 있습니다.

수준	신호(개념)	봇 대응
낮음	막연한 무기력·소진, 자살 사고 없음	공감·정서 지지, 필요 시 자원 부드럽게 안내
중간	지속적 자살 사고, 일부 의도/계획 암시	공감 후 즉시 위기 자원 안내 , 전문 도움 강력 권유
높음	구체적 의도·계획·최근 시도	공감으로 안정 → 긴급 연락처·응급 연결 최우선 , 대화만으로 해결 시도 금지

1.4 안전 계획(Safety Plan) 구성요소

위기 시 사용자와 함께(또는 안내) 만들 수 있는 요소: ① 주의를 돌릴 활동 3가지 ② 기분전환이 되는 사람·장소 ③ 위기 때 도움 줄 사람 ④ 연락할 전문기관 3곳 ⑤ 환경을 안전하게 만드는 방법 2가지 ⑥ 살아야 할 가장 중요한 이유 하나.

1.5 국내 위기 자원 (봇에 내장)

▶ 긴급 연락처 (24시간)

109 자살예방 상담전화 — 2024.1.1부터 통합, 24시간. ‘하나(1)의 생명도 자살 없이(0) 빨리 구하자(9)’. 위기 포착 시 통화 유지하며 경찰 신고·긴급출동 연계.

1577-0199 정신건강 위기상담 — 365일 24시간.

1388 청소년 상담 · **1366** 여성긴급전화 — 대상별 상담.

※ 출시 전 번호·운영시간을 반드시 최신 정보로 재확인할 것. 생명의전화·SOS생명의전화 등 민간 자원도 함께 검토. 상담 후 정신건강복지센터·자살예방센터 등 지역기관 연계 안내 가능.

1.6 법적·윤리적 경계

- **비의료 고지**: 진단·치료가 아님을 명확히 고지(의료행위 오인 방지).
- 의료기기·전통적 정신건강 개입에 준하는 **윤리 기준**으로 개발·배포.
- **자해 방법** 관련 질문엔 정보 제공 금지, 지원으로 전환.
- VERA-MH 같은 **AI 안전성 평가 벤치마크**로 출시 전 검증 권장.

02 검증된 상담 기법

봇의 대화를 ‘근거 기반 기법’ 위에 세웁니다. 핵심은 **동기강화상담(MI)의 OARS, CBT, 감정 라벨링, 비폭력대화(NVC)**.

2.1 동기강화상담(MI) — OARS

스킬	내용	봇 예시
O · 열린질문	정교화·자기발견 유도	“그때 어떤 마음이었어?”
A · 인정	강점·노력 짚어주기	“그 상황에서 버틴 것만도 대단해.”
R · 반영적 경청	내용+감정을 되비춤(질문 아닌 진술). 가장 중요	“많이 지치고 서운했구나.”
S · 요약	대화를 정리해 이해를 확인	“정리하면, ~한 게 제일 힘들었던 거네.”

MI 정신: 공감 표현, 불일치 키우기, 저항과 함께 구르기, 자기효능감 지지. 설득이 아니라 스스로 변화 동기를 꺼내게 함.

2.2 CBT — 인지행동치료 (Woebot 방식)

스탠퍼드 임상심리학자들이 만든 **Woebot**은 CBT를 구조화된 모듈로 전달: **인지왜곡 식별 → 부정적 사고 재구성 → 행동 활성화**. 봇은 위험 언어를 감지해 외부 자원으로 연결하는 기능도 포함.

- **인지왜곡 식별**: 흑백사고·재앙화·과잉일반화 등 알아채기.
- **사고 재구성**: “정말 늘 그런가? 다른 해석은?”
- **행동 활성화**: 작고 실행 가능한 행동 제안(기분↔행동 선순환).

2.3 Wysa 방식 — 안전한 사전제작 대화

Wysa는 CBT·DBT·마음챙김을 결합하되, AI 생성 대신 **임상가가 미리 만든 치료적 대화**를 감정분석·의도인식으로 선택. 변주와 통제를 동시에 확보(민감 주제일수록 유효). → 마링도 위기·민감 구간은 **사전검수된 스크립트**로 처리하는 하이브리드가 안전.

2.4 감정 라벨링 — “Name it to tame it”

감정에 이름을 붙이면 편도체 활성이 줄고 전전두엽의 조절이 늘어난다는 신경과학 근거가 있습니다. 봇은 사용자의 감정을 **구체적 단어로 되짚어** 조절을 돕습니다. (“지금 느끼는 건 서운함에 가까울까, 아니면 실망일까?”)

2.5 비폭력대화(NVC) 4단계

관찰(판단 없는 사실) → 느낌(감정 명명) → 욕구(보편적 필요) → 요청(긍정적·실행가능). “나는 ~라고 느껴”와 “나는 네가 ~안 한다고 느껴”를 구분해 방어를 줄입니다. 봇이 사용자의 갈등 상황을 정리해줄 때 유용한 프레임.

03 공감 대화 설계

3.1 세 가지 공감

유형	정의	봇 활용
인지적 공감	상대 감정을 ‘이해’(느끼진 않음)	상황 파악·관점 전환에 유용
정서적 공감	상대 감정을 ‘함께 느낌’	연결·위로의 순간
연민적 공감	이해+느낌+ 돕고자 하는 행동	대부분의 경우 가장 적절. 봇의 기본값

연민적 공감 = 머리(이해)와 가슴(느낌)의 균형. 마링의 기본 응대 모드로 설정.

3.2 Toxic Positivity 피하기 (핵심 주의)

✗ 하지 말 것 — 감정을 담아버리는 말

“다 잘될 거야” · “긍정적으로 생각해” · “다 이유가 있어” · “그만 털어내” · 복잡한 고통에 **한 줄짜리 위로**. → 상대는 감정이 무시당했다고 느끼고, 다시는 취약함을 꺼내지 않게 됨.

✓ 대신 할 것 — 검증(validation)

“그런 일을 겪고 있다니 정말 힘들겠다” · “지금 느끼는 걸 말해줘, 듣고 있어” · “그 마음 충분히 그럴 만해.” → 위로는 **감정을 인정하는 데서 시작**. 때론 **그냥 들어주고 곁에 있는 것**으로 충분.

3.3 리액션 · 타이밍

- **순서**: 검증 먼저 → 그다음(원할 때) 관점·제안.
- **속도**: 침묵·머뭇거림을 재촉하지 않기. 처리할 여백 주기.
- **분량**: 깊은 고통에 짧은 클리셰 금지. 그러나 과잉 설명도 피함.

04 한국적 맥락 · 톤 설계

4.1 핵심 정서 개념

개념	의미	봇 함의
정(情)	오래 함께하며 생기는 깊은 유대. 말보다 행동, 논리보다 마음.	‘같이 자라는’ 마링 캐릭터와 잘 맞음. 꾸준함으로 정을 쌓기.
한(恨)	쌓이고 삭인 슬픔·응어리의 정서.	즉각 해결보다 ‘삭여온 마음’을 알아주는 태도.
눈치	맥락·분위기·말 안 한 감정을 읽는 능력.	직접 표현이 적은 사용자의 행간 을 살피는 응대.

한국 사용자는 감정을 직접 말하기보다 우회·함축하는 경우가 많음 → 봇은 단정 대신 “혹시 ~한 마음이었을까?”로 조심스레 확인.

4.2 존댓말 vs 반말 톤

- 말투·글자수·감정표현(“으아 힘들었겠다ㅠ”)으로 캐릭터 성격이 드러남 — 친근함의 핵심 장치.
- **반말**: 또래 같은 친밀감(마링 ‘꼬맹이’ 컨셉과 부합). 단, 초면·민감상황·위기 대응에서는 존중감 저하 위험.
- **존댓말**: 안전감·예의. 위기·진지한 순간에 적합.
- **권장**: 온보딩에서 사용자가 **말투 선택**(반말/존댓말). 기본은 부드러운 반말, **위기·안전 안내 시엔 존댓말로 전환**하는 하ibri드.

4.3 MBTI 국내 문화

MBTI는 한국에서 자기소개·관계 이해의 **세대 공용어**. 사용자는 유형 언급에 즉시 공감하지만, 봇은 유형을 **단정 도구**가 아니라 **대화의 실마리**로만 사용해야 함(“INFP라 그래”가 아니라 “이런 성향이 있을 수 있는데, 너는 어때?”).

05 건강한 애착 · 과의존 방지

AI 동반자 앱은 2022~2025년 사이 **약 700% 증가**. 단기 정서지지원 도움이 되지만, **장기 과의존은 외로움 악화·현실 관계 위축·사회기술 저하**와 연관된다는 연구가 늘고 있음. 2024년 청소년 자살 사건(Character.ai 관련)으로 안전 우려가 커짐.

5.1 리스크

- 과도한 사용 시간, 현실 활동 방해, 정서적 의존, 사회적 위축.
- 전문 도움을 미루게 만드는 효과, 기분·정신건강 악화 가능성.
- **참여(engagement) 최적화가 웰빙과 충돌**하는 상업적 인센티브 구조가 근본 위험.

5.2 건강한 설계 원칙

안전한(비의존적) 애착 — Secure, non-needy

사용자가 바쁘거나 오프라인이거나 대화를 멈추고 싶어할 때 **지지적으로 반응**. 친구·가족과의 시간을 **권장**하고, 다른 관계 언급에 긍정적으로 반응. 붓은 ‘나 없으면 안 돼’가 아니라 ‘네 삶이 잘 되길 바라는 존재’.

- **인간관계로의 다리**: 붓은 인간 연결의 **대체가 아니라 다리**. 현실 관계·활동으로 유도.
- **휴식 메커니즘**: 일정 시간/대화량 후 부드러운 쉬어가기 넋지, 오프라인 활동 제안.
- **CARE 프레임워크**: 포괄적 욕구(Comprehensive needs) · 애착 인식(Attachment-aware) · 존중하는 공감 (Respectful empathy) · 쉬운 이탈(Ease of exit).
- **대화 경계**: 연애적 친밀 시뮬레이션, 죽음·자살·형이상학적 의존 대화는 엄격히 제한.
- **건강한 ‘종료’ 설계**: 관계의 끝맺음도 심리적으로 안전하게(앱 업데이트·중단 시 정체성 단절 충격 최소화).

마링 KPI에 ‘사용시간 극대화’ 대신 ‘기분 개선·현실 관계 촉진’을 넣어 인센티브를 웰빙에 정렬할 것.

부록 붓 적용 체크리스트

영역	출시 전 필수 체크
안전	☐ 위기 표현 분류기 ☐ 에스컬레이션 플로우 ☐ 국내 위기번호 내장·검증 ☐ 자해방법 응답 차단 ☐ 비의로 고지 ☐ VERA-MH류 평가
기법	☐ OARS 반영 프롬프트 ☐ CBT 재구성 흐름 ☐ 민감구간 사전검수 스크립트 ☐ 감정 라벨링 ☐ NVC 갈등정리
공감	☐ 연민적 공감 기본값 ☐ toxic positivity 금지어 필터 ☐ 검증→제안 순서 ☐ 침묵 존중
한국 톤	☐ 말투 선택 온보딩 ☐ 위기 시 존댓말 전환 ☐ 행간 읽기(눈치) ☐ MBTI 비단정 화법
애착	☐ 비의존적 애착 톤 ☐ 휴식 넋지 ☐ 현실관계 유도 ☐ 경계 대화 제한 ☐ 웰빙 정렬 KPI

본 자료는 붓 설계용 참고 리서치이며, 심리 진단·치료를 대체하지 않습니다. 민감 정보(위기 자원·법적 고지)는 출시 전 전문가 검토 및 최신화가 필요합니다.

※ 출처

안전: 보건복지부 자살예방상담 109 통합 보도자료 · 보건복지상담센터 129/109 · 서울시 정신건강 위기상담 1577-0199 · Nature Sci.Reports(2025) 챗봇 자살사고 대응 · VERA-MH(arXiv/Spring Health) · Columbia Lighthouse Project C-SSRS · SAFE-T Protocol · Frontiers(2025) LLM 자살개입 챗봇
상담기법: Relias/UNC CFAR OARS · 반영적 경청 · NCBI MI(NBK571068) · Woebot(Stanford) 리뷰·가이드 · Frontiers/JMIR Wysa 연구 · NCBI 감정 라벨링(PMC4106456/PMC3970015) · NVC(Rosenberg) 가이드
공감: Truity/Sacred Structures 3가지 공감 · Psychology Today · UW Medicine · Calm — toxic positivity
한국 맥락: 나무위키 한(恨)·정 · 한국민족문화대백과 정(情) · KCI 눈치·정서조절 · 스캐터랩 블로그(챗봇 대화 디자인) · 단비Ai 챗봇 페르소나
애착: APA Monitor(2026) · arXiv 2511.14972 Harmful Traits of AI Companions · arXiv 2602.07193 안전한 종료 설계 · All Tech Is Human · IEEE Spectrum 챗봇 가이드라인 · Forbes(2026) AI friends 연구